

Analisis Diskriminan

Ferdian Bangkit Wijaya, S.Stat., M.Si.

Konsep Dasar

- Analisis Diskriminan (AD) adalah teknik statistika multivariat yang digunakan untuk mengklasifikasikan objek ke dalam beberapa kelompok ($g \geq 2$) yang telah ditentukan sebelumnya (supervised). Klasifikasi ini dilakukan berdasarkan sekumpulan variabel prediktor (x) yang bersifat kontinu.
- Tujuan utama:
 - Pemisahan (Separation): Menentukan variabel prediktor mana yang paling kuat membedakan antar kelompok.
 - Klasifikasi (Classification): Membuat aturan atau fungsi untuk menempatkan observasi baru ke dalam kelompok yang paling sesuai.
- Analisis Diskriminan mencari kombinasi linear dari variabel-variabel x sehingga rasio varians antar kelompok terhadap varians di dalam kelompok menjadi maksimum.

Asumsi

Agar fungsi diskriminan bersifat optimal (terutama untuk Linear Discriminant Analysis), beberapa asumsi harus dipenuhi:

- Normalitas Multivariat: Variabel prediktor di setiap kelompok berdistribusi normal multivariat.
- Homogenitas Varian-Kovarian: Matriks varian-kovarian di setiap kelompok dianggap sama ($\Sigma_1 = \Sigma_2 = \dots = \Sigma_g = \Sigma$).
- Independensi: Observasi antar individu bersifat independen satu sama lain.

Matriks Varians-Covarians Pooled

- Untuk kasus dengan **g** populasi/grup, rumus Matriks Varians-Covarians menggunakan prinsip **rata-rata terboboti** dari matriks varian-kovarian masing-masing grup berdasarkan derajat bebasnya:

$$\mathbf{S}_{\text{pooled}} = \frac{\sum_{i=1}^g (n_i - 1) \mathbf{S}_i}{\left(\sum_{i=1}^g n_i\right) - g}$$

- Atau jika kita menggunakan **N** sebagai total seluruh observasi ($N = n_1 + n_2 + \dots + n_g$), rumusnya menjadi:

$$\mathbf{S}_{\text{pooled}} = \frac{(n_1 - 1) \mathbf{S}_1 + (n_2 - 1) \mathbf{S}_2 + \dots + (n_g - 1) \mathbf{S}_g}{N - g}$$

Misal :

Jika ada 2 Populasi, maka akan terbentuk S1 (berukuran $p \times p$) dan S2 (berukuran $p \times p$),

Jika ada 3 Populasi maka akan terbentuk S1 (berukuran $p \times p$), S2 (berukuran $p \times p$), dan S3 (berukuran $p \times p$) dan seterusnya..

Ukuran matriks **S_{pooled}** ($p \times p$) dengan p adalah banyaknya variable x .

Diskriminan dengan 2 Populasi/ Grup

Koefisien Fungsi Diskriminan Fisher

- Tujuan kita adalah mencari vektor koefisien $\mathbf{a}' = [a_1, a_2, \dots, a_p]$ yang memaksimalkan pemisahan antar grup. Koefisien ini dihitung dengan rumus:

$$\mathbf{a} = \mathbf{S}_{\text{pooled}}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$$

- Fungsi diskriminan linear sebanyak : $\min(g - 1, p)$
- Fungsi diskriminan linear yang terbentuk adalah:

$$Z = a_1x_1 + a_2x_2 + \dots + a_px_p$$

Prosedur Klasifikasi : Nilai Ambang Batas (Cut-off Point)

- Setelah fungsi $\mathbf{Z}$ terbentuk, perlu menentukan nilai kritis (m_0) sebagai batas klasifikasi. Nilai ini merupakan rata-rata dari skor diskriminan kedua grup:

$$m_0 = \frac{1}{2}(\bar{Z}_1 + \bar{Z}_2)$$

atau secara matriks:

$$m_0 = \frac{1}{2}\mathbf{a}'(\bar{\mathbf{x}}_1 + \bar{\mathbf{x}}_2)$$

Ilustrasi untuk 2 Populasi

No	Grup (y)	x1	x2	x3
1	1	5	10	2
2	1	6	12	1
3	1	4	11	3
4	1	7	13	2
5	1	5	9	2
6	2	2	5	8
7	2	3	6	7
8	2	2	4	9
9	2	4	5	8
10	2	3	7	7

Implementasi di R

Input Data

```
df <- data.frame( y =  
c(rep(1, 5), rep(2, 5)), x1 =  
c(5, 6, 4, 7, 5, 2, 3, 2, 4, 3),  
x2 = c(10, 12, 11, 13, 9, 5,  
6, 4, 5, 7), x3 = c(2, 1, 3,  
2, 2, 8, 7, 9, 8, 7))
```

df

Ilustrasi untuk 2 Populasi

- Langkah 1: Hitung Vektor Rata-rata (Mean Vectors)

Hitung rata-rata tiap variabel untuk masing-masing grup:

Grup1($\bar{\mathbf{x}}_1$):

$$\begin{aligned}\bar{x}_{11} &= (5 + 6 + 4 + 7 + 5)/5 = 5.4 \\ \bar{x}_{12} &= (10 + 12 + 11 + 13 + 9)/5 = 11.0 \\ \bar{x}_{13} &= (2 + 1 + 3 + 2 + 2)/5 = 2.0\end{aligned}$$

$$\bar{\mathbf{x}}_1 = [5.4, 11.0, 2.0]'$$

Grup2($\bar{\mathbf{x}}_2$):

$$\begin{aligned}\bar{x}_{21} &= (2 + 3 + 2 + 4 + 3)/5 = 2.8 \\ \bar{x}_{22} &= (5 + 6 + 4 + 5 + 7)/5 = 5.4 \\ \bar{x}_{23} &= (8 + 7 + 9 + 8 + 7)/5 = 7.8\end{aligned}$$

$$\bar{\mathbf{x}}_2 = [2.8, 5.4, 7.8]'$$

```
> # Hitung Vektor Rata-rata (Mean Vectors)
> x_bar1 <- colMeans(df[df$y == 1, 2:4])
> x_bar2 <- colMeans(df[df$y == 2, 2:4])
> x_bar1
  x1    x2    x3
5.4 11.0  2.0
> x_bar2
  x1    x2    x3
2.8  5.4  7.8
```

Ilustrasi untuk 2 Populasi

- Langkah 2: Hitung Matriks Varian-Kovarian Gabungan (S_{pooled})

$$S_{\text{pooled}} = \frac{(n_1 - 1)S_1 + (n_2 - 1)S_2}{n_1 + n_2 - 2}$$

$$S_{\text{pooled}} = \begin{bmatrix} 1.000 & 0.800 & -0.400 \\ 0.800 & 1.900 & -0.575 \\ -0.400 & -0.575 & 0.600 \end{bmatrix}$$

$$S_{\text{pooled}}^{-1} = \begin{bmatrix} 1.6539 & -0.5109 & 0.6130 \\ -0.5109 & 0.8991 & 0.5211 \\ 0.6130 & 0.5211 & 2.5747 \end{bmatrix}$$

```
> # Hitung Matriks Varian-Kovarian Gabungan (S_pooled)
> n1 <- 5; n2 <- 5
> S1 <- cov(df[df$y == 1, 2:4])
> S1
      x1      x2      x3
x1  1.30  1.25 -0.50
x2  1.25  2.50 -0.25
x3 -0.50 -0.25  0.50
> S2 <- cov(df[df$y == 2, 2:4])
> S2
      x1      x2      x3
x1  0.70  0.35 -0.3
x2  0.35  1.30 -0.9
x3 -0.30 -0.90  0.7
> S_pooled <- ((n1 - 1) * S1 + (n2 - 1) * S2) / (n1 + n2 - 2)
> S_pooled
      x1      x2      x3
x1  1.0  0.800 -0.400
x2  0.8  1.900 -0.575
x3 -0.4 -0.575  0.600
>
> # Hitung Koefisien Diskriminan (a)
> S_inv <- solve(S_pooled) # Invers matriks
> S_inv
      x1      x2      x3
x1  1.6538953 -0.5108557 0.6130268
x2 -0.5108557  0.8991060 0.5210728
x3  0.6130268  0.5210728 2.5747126
```


Ilustrasi untuk 2 Populasi

- Langkah 3: Hitung Koefisien Diskriminan **a**

$$\mathbf{a} = \mathbf{S}_{\text{pooled}}^{-1}(\bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2)$$

Hitung Selisih Rata-rata (**d**)

$$\mathbf{d} = \bar{\mathbf{x}}_1 - \bar{\mathbf{x}}_2 = \begin{bmatrix} 5.4 - 2.8 \\ 11.0 - 5.4 \\ 2.0 - 7.8 \end{bmatrix} = \begin{bmatrix} 2.6 \\ 5.6 \\ -5.8 \end{bmatrix}$$

$$\mathbf{S}_{\text{pooled}}^{-1} = \begin{bmatrix} 1.6539 & -0.5109 & 0.6130 \\ -0.5109 & 0.8991 & 0.5211 \\ 0.6130 & 0.5211 & 2.5747 \end{bmatrix}$$

Koefisien Fisher Diskriminan **a**

- $a_1 : (1.6538953 \times 2.6) + (-0.5108557 \times 5.6) + (0.6130268 \times -5.8)$
 $= 4.3001 - 2.8608 - 3.5556 = -2.1162$
- $a_2 : (-0.5108557 \times 2.6) + (0.8991060 \times 5.6) + (0.5210728 \times -5.8)$
 $= -1.3282 + 5.0350 - 3.0222 = 0.6845$
- $a_3 : (0.6130268 \times 2.6) + (0.5210728 \times 5.6) + (2.5747126 \times -5.8)$
 $= 1.5939 + 2.9180 - 14.9333 = -10.4215$

```
> a <- S_inv %*% (x_bar1 - x_bar2)
> round(a, 4)
      [,1]
x1 -2.1162
x2  0.6845
x3 -10.4215
```

Fungsi Diskriminan:

$$Z = -2.1162x_1 + 0.6845x_2 - 10.4215x_3$$

Ilustrasi untuk 2 Populasi

- Langkah 4: Hitung Titik Potong (Cut-off m_0)

Cari skor $\bar{Z}$ untuk masing-masing rata-rata grup terlebih dahulu:

$\bar{Z}_1$ (Grup 1):

$$(-2.1162 \times 5.4) + (0.6845 \times 11.0) - (10.4215 \times 2.0) = -24.7410$$

$\bar{Z}_2$ (Grup 2):

$$(-2.1162 \times 2.8) + (0.6845 \times 5.4) - (10.4215 \times 7.8) = -83.5168$$

Nilai Cut-off (m_0):

$$m_0 = \frac{\bar{Z}_1 + \bar{Z}_2}{2} = \frac{-24.7410 + (-83.5168)}{2} = -54.128$$

Langkah 5: Prosedur Klasifikasi

Karena $\bar{Z}_1(-24.74) > \bar{Z}_2(-83.51)$, maka aturannya adalah:

- Grup 1** jika $Z \geq -54.128$
- Grup 2** jika $Z < -54.128$

```
> # Hitung Nilai Cut-off (m0)
> m0 <- 0.5 * t(a) %*% (x_bar1 + x_bar2)
> as.numeric(m0)
[1] -54.12835
```

Ilustrasi untuk 2 Populasi

- Langkah 6 : Bagaimana jika ada data baru di x_1 , x_2 , dan x_3 ?

Misalkan kita punya data baru, si "A" dengan karakteristik:

$$x_1 = 5, x_2 = 10, x_3 = 3$$

1. Hitung Skor Diskriminan (Z_A):

- Masukkan nilai x ke dalam fungsi:

$$Z = -2.1162x_1 + 0.6845x_2 - 10.4215x_3$$

$$Z_A = (-2.1162 \times 5) + (0.6845 \times 10) - (10.4215 \times 3)$$

$$Z_A = -10.581 + 6.845 - 31.2645$$

$$Z_A = -35.0005$$

2. Bandingkan dengan Cut-off ($m_0 = -54.1289$):

- Karena $Z_A(-35.00) \geq -54.13$, maka "Si A" diklasifikasikan ke Grup 1.

```
> # Data Si A (sebagai vektor)
> x_A <- c(5, 10, 3)
>
> # Hitung Skor Z
> # Rumus: a1*x1 + a2*x2 + a3*x3
> Z_A <- sum(a * x_A)
>
> # Bandingkan dengan m0
> m0_nilai <- as.numeric(m0)
>
> # Tampilkan Keputusan
> print(paste("Skor Z Si A:", round(Z_A, 4)))
[1] "skor Z Si A: -35"
> if(Z_A >= m0_nilai){
+   print("Hasil: Masuk Grup 1")
+ } else {
+   print("Hasil: Masuk Grup 2")
+ }
[1] "Hasil: Masuk Grup 1"
```

Ilustrasi untuk 2 Populasi

- Langkah 7 : Variable mana yang paling berpengaruh dalam pemisah grup 1 dan 2 ?

Berdasarkan matriks $\mathbf{S}_{\text{pooled}}$, dan koefisien $\mathbf{a}$

$$\mathbf{S}_{\text{pooled}} = \begin{bmatrix} 1.000 & 0.800 & -0.400 \\ 0.800 & 1.900 & -0.575 \\ -0.400 & -0.575 & 0.600 \end{bmatrix} ; \mathbf{a} = [-2.1162, ; 0.6845; 10.4215]$$

Ambil nilai varians di diagonal utama (s_{11}, s_{22}, s_{33}) pada $\mathbf{S}_{\text{pooled}}$:

- $s_{11} = 1.0 \Rightarrow sd_1 = \sqrt{1.0} = 1.0$
- $s_{22} = 1.9 \Rightarrow sd_2 = \sqrt{1.9} \approx 1.3784$
- $s_{33} = 0.6 \Rightarrow sd_3 = \sqrt{0.6} \approx 0.7746$

Sekarang kalikan dengan koefisien $\mathbf{a}$ yang sudah dihitung:

- Variabel x_1 : $-2.1162 \times 1.0 = -2.1162$
- Variabel x_2 : $0.6845 \times 1.3784 = 0.9435$
- Variabel x_3 : $-10.4215 \times 0.7746 = -8.0725$

Lihat Nilai Absolut (Mutlak) yang paling besar.

- $|x_3| = 8.0725$ (Variabel yang paling berpengaruh)
- $|x_1| = 2.1162$
- $|x_2| = 0.9435$

Ilustrasi untuk 2 Populasi

- Perbandingan Output Perhitungan Manual dengan R

- Jika perhitungan manual didapatkan:

$$Z = -2.1162x_1 + 0.6845x_2 - 10.4215x_3$$

- Jika menggunakan library MASS di R didapatkan:

$$LD1 = 0.2760x_1 - 0.0893x_2 + 1.3593x_3$$

Fungsi lda() di R memaksa koefisien tersebut agar memenuhi syarat:

$$\mathbf{a}'\mathbf{S}_{\text{pooled}}\mathbf{a} = 1$$

Artinya, R mengatur agar varians di dalam grup (within-group variance) dari skor diskriminan Z tepat bernilai 1.

HASILNYA SAMA SAJA :

Hitungan Manual:


$$a_1/a_3 = -2.1162/-10.4215 = 0.203$$

Output lda() di R:

$$LD1_{x1}/LD1_{x3} = 0.2760/1.3593 = 0.203$$

```
> library(MASS)
> model_lda <- lda(y ~ x1 + x2 + x3, data = df)
> model_lda$scaling
              LD1
x1  0.27603345
x2 -0.08929024
x3  1.35934397
```

Contoh Visualisasi untuk 2 Populasi dan 3 X



Karena hanya ada 1 Fungsi Diskriminan, maka pemisah antar 2 Grup Populasi Adalah “Garis”

Diskriminan dengan > 2 Populasi/ Grup

Koefisien Fungsi Klasifikasi Linear

- Tujuan kita adalah mencari vektor koefisien $\mathbf{a}'_k = [a_{k1}, a_{k2}, \dots, a_{kp}]$ untuk setiap grup ($k = 1, 2, 3$) yang akan digunakan untuk menghitung skor keanggotaan. Koefisien ini dihitung dengan rumus:

$$\mathbf{a}_k = \mathbf{S}_{\text{pooled}}^{-1} \overline{\mathbf{x}}_k$$

- Setiap grup juga memiliki Konstanta Klasifikasi (a_{k0}) yang berfungsi sebagai intersep bagi masing-masing kelompok:

$$a_{k0} = -\frac{1}{2} \mathbf{a}'_k \overline{\mathbf{x}}_k$$

- Fungsi Klasifikasi Linear (Skor Keanggotaan):

$$L_k = a_{k0} + a_{k1}x_1 + a_{k2}x_2 + \dots + a_{kp}x_p$$

- Fungsi Multiple Discriminant:

$$\min(g - 1, p)$$

Prosedur Klasifikasi

- Klasifikasikan observasi ke dalam grup yang menghasilkan **Skor L_k Tertinggi**.

$$\text{Pilih Grup } k \text{ jika: } L_k = \max(L_1, L_2, L_3)$$

Ilustrasi untuk 3 Populasi

- Jika diketahui :

- Vektor Rata-rata ($\overline{\mathbf{x}}_k$):

$$\overline{\mathbf{x}}_1 = \begin{bmatrix} 10 \\ 15 \end{bmatrix}, \quad \overline{\mathbf{x}}_2 = \begin{bmatrix} 5 \\ 5 \end{bmatrix}, \quad \overline{\mathbf{x}}_3 = \begin{bmatrix} 15 \\ 5 \end{bmatrix}$$

- Matriks $\mathbf{S}_{\text{pooled}}$:

$$\mathbf{S}_{\text{pooled}} = \begin{bmatrix} 1.36 & 0.45 \\ 0.45 & 1.82 \end{bmatrix}$$

- Matriks Invers Varian-Kovarian Gabungan ($\mathbf{S}_{\text{pooled}}^{-1}$):

$$\mathbf{S}_{\text{pooled}}^{-1} = \begin{bmatrix} 0.8 & -0.2 \\ -0.2 & 0.6 \end{bmatrix}$$

Ilustrasi untuk 3 Populasi

Langkah 1: Hitung Koefisien Tiap Grup ($\mathbf{a}_k = \mathbf{S}_{\text{pooled}}^{-1} \bar{\mathbf{x}}_k$)

- Grup 1: $\mathbf{a}_1 = \begin{bmatrix} 0.8 & -0.2 \\ -0.2 & 0.6 \end{bmatrix} \begin{bmatrix} 10 \\ 15 \end{bmatrix} = \begin{bmatrix} (8 - 3) \\ (-2 + 9) \end{bmatrix} = \begin{bmatrix} 5 \\ 7 \end{bmatrix}$
- Grup 2: $\mathbf{a}_2 = \begin{bmatrix} 0.8 & -0.2 \\ -0.2 & 0.6 \end{bmatrix} \begin{bmatrix} 5 \\ 5 \end{bmatrix} = \begin{bmatrix} (4 - 1) \\ (-1 + 3) \end{bmatrix} = \begin{bmatrix} 3 \\ 2 \end{bmatrix}$
- Grup 3: $\mathbf{a}_3 = \begin{bmatrix} 0.8 & -0.2 \\ -0.2 & 0.6 \end{bmatrix} \begin{bmatrix} 15 \\ 5 \end{bmatrix} = \begin{bmatrix} (12 - 1) \\ (-3 + 3) \end{bmatrix} = \begin{bmatrix} 11 \\ 0 \end{bmatrix}$

Langkah 2: Hitung Konstanta Klasifikasi ($a_{k0} = -\frac{1}{2} \mathbf{a}'_k \bar{\mathbf{x}}_k$)

- $a_{10}: -0.5 \times [(10 \times 5) + (15 \times 7)] = -0.5 \times [50 + 105] = -77.5$
- $a_{20}: -0.5 \times [(5 \times 3) + (5 \times 2)] = -0.5 \times [15 + 10] = -12.5$
- $a_{30}: -0.5 \times [(15 \times 11) + (5 \times 0)] = -0.5 \times [165 + 0] = -82.5$

Ilustrasi untuk 3 Populasi

Langkah 3: Fungsi Klasifikasi Linear yang Terbentuk

Berdasarkan hasil di atas, kita peroleh tiga fungsi skor klasifikasi:

- $L_1 = -77.5 + 5x_1 + 7x_2$
- $L_2 = -12.5 + 3x_1 + 2x_2$
- $L_3 = -82.5 + 11x_1 + 0x_2$

Langkah 4: Klasifikasi Observasi Baru

- Misalkan ada data baru dengan nilai $x_1 = 12$ dan $x_2 = 10$. Ke manakah data ini akan dikelompokkan?
- Hitung L_1 : $-77.5 + 5(12) + 7(10) = -77.5 + 60 + 70 = 52.5$
- Hitung L_2 : $-12.5 + 3(12) + 2(10) = -12.5 + 36 + 20 = 43.5$
- Hitung L_3 : $-82.5 + 11(12) + 0(10) = -82.5 + 132 + 0 = 49.5$

Karena skor L_1 adalah yang paling tinggi (maksimum), maka observasi baru tersebut diklasifikasikan masuk ke dalam **Grup 1**.

Ilustrasi untuk 3 Populasi

Langkah 5: Menentukan Variabel Paling Berpengaruh (Separator)

$$S_{\text{pooled}} = \begin{bmatrix} 1.36 & 0.45 \\ 0.45 & 1.82 \end{bmatrix}$$

Standar Deviasi Gabungan (sd):

- $sd_1 = \sqrt{1.36} \approx 1.17$
- $sd_2 = \sqrt{1.82} \approx 1.35$

• Grup 1

Koefisien $\mathbf{a}_1 = [5, 7]'$

$x_1: 5 \times 1.17 = 5.85$

$x_2: 7 \times 1.35 = 9.45$

Karakteristik: Didominasi oleh x_2

• Grup 2

Koefisien $\mathbf{a}_2 = [3, 2]'$

$x_1: 3 \times 1.17 = 3.51$

$x_2: 2 \times 1.35 = 2.70$

Karakteristik: Didominasi oleh x_1 .

• Grup 3

Koefisien $\mathbf{a}_3 = [11, 0]'$

$x_1: 11 \times 1.17 = 12.87$

$x_2: 0 \times 1.35 = 0$

Karakteristik: Didominasi mutlak oleh x_1 .

Ilustrasi untuk 3 Populasi

Langkah 6: Fungsi Multiple Diskriminan yang Terbentuk

- Karena hanya diketahui vektor rata-rata dan Spooled saja, maka fungsi `lda()` tidak bisa digunakan, harus menggunakan raw data, oleh sebab itu akan dibuat simulasi data yg menghasilkan parameter vektor rata-rata dan Spooled yang sama :
- Jika menggunakan library MASS di R didapatkan:

$$LD1 = 0.7621x_1 - 0.5951x_2$$

$$LD2 = 0.5315x_1 + 0.5179x_2$$

```
> print(model$scaling)
      LD1      LD2
x1 0.7621463 0.5314960
x2 -0.5950944 0.5170329
```


```
library(MASS)

# Parameter dari slide
mu1 <- c(10, 15)
mu2 <- c(5, 5)
mu3 <- c(15, 5)
mu_matrix <- rbind(mu1, mu2, mu3)
mu_matrix
Spooled <- matrix(c(1.36, 0.45, 0.45, 1.82), nrow = 2, byrow = TRUE)
Spooled
Spooled_inv <- solve(Spooled)
Spooled_inv
# Simulasi 100 data per grup
set.seed(123)
g1 <- mvrnorm(100, mu1, Spooled)
g2 <- mvrnorm(100, mu2, Spooled)
g3 <- mvrnorm(100, mu3, Spooled)
df_simulasi <- data.frame(
  y = factor(rep(1:3, each = 100)),
  x1 = rbind(g1, g2, g3)[,1],
  x2 = rbind(g1, g2, g3)[,2]
)

# Jalankan LDA
model <- lda(y ~ x1 + x2, data = df_simulasi)



# Memunculkan Koefisien LD1 dan LD2
print(model$scaling)
```

Contoh Visualisasi untuk 3 Populasi dan 2 X



Karena ada 2 Fungsi Diskriminan, maka pemisah antar 3 Grup Populasi Adalah “Bidang 2 dimensi”

Contoh Visualisasi untuk 4 Populasi dan 3 X



Karena ada 3 Fungsi Diskriminan, maka pemisah antar 4 Grup Populasi Adalah “Bidang 3 dimensi”

Uji Signifikansi Diskriminan

Wilks' Lambda adalah statistik uji yang digunakan untuk mengukur seberapa baik fungsi diskriminan memisahkan grup-grup yang ada. Dalam statistik, ini sering disebut sebagai "Uji Kebalikan" dari varians yang dijelaskan.

- Mendekati 0: Menunjukkan bahwa varians dalam grup kecil dibandingkan varians antar grup. Artinya, fungsi sangat kuat dan hebat membedakan kelompok.
- Mendekati 1: Menunjukkan bahwa varians dalam grup hampir sama dengan varians total. Artinya, grup-grup tersebut sangat tumpang tindih dan fungsi lemah (tidak berguna).
- Hipotesis Pengujian:
 - H_0 : Tidak ada perbedaan rata-rata skor diskriminan antar grup (Fungsi tidak signifikan).
 - H_1 : Minimal ada satu perbedaan rata-rata skor diskriminan antar grup (Fungsi signifikan).

Uji Signifikansi Diskriminan

- **Hubungan Eigenvalue dan Wilks' Lambda**
- Wilks' Lambda juga berkaitan dengan **Eigenvalue** (λ). Semakin besar Eigenvalue suatu fungsi, maka semakin kecil Wilks' Lambdanya, yang berarti semakin besar daya pembeda fungsi tersebut.

$$\Lambda = \prod_{i=1}^k \frac{1}{1 + \lambda_i}$$

Uji Signifikansi Diskriminan

• Mencari Eigenvalue

```
> # 1. Cari Eigen value
>
> # 1. Hitung Matriks B (Between-group) dengan n=100
> n <- 100
> mu_grand <- colMeans(mu_matrix)
> B <- n * ( (mu1 - mu_grand) %*% t(mu1 - mu_grand) +
+           (mu2 - mu_grand) %*% t(mu2 - mu_grand) +
+           (mu3 - mu_grand) %*% t(mu3 - mu_grand) )
>
> # 2. Hitung Matriks W (Within-group) dengan df=297
> W <- (300 - 3) * Spooled
>
> # 3. Hitung Eigenvalue dari  $W^{-1} * B$ 
> eigenvalues <- eigen(solve(W) %*% B)$values
>
> # Tampilkan Hasil
> print(eigenvalues)
[1] 17.306079 9.607824
```

• Mencari Wilks Lamda

```
> # 1. Input Eigenvalue Baru (Hasil n=100 per grup)
> eigenvalues <- c(17.306079, 9.607824)
>
> # 2. Hitung Wilks' Lambda
> # Rumus: Produk dari  $1 / (1 + \lambda)$ 
> wilks_lambda <- prod(1 / (1 + eigenvalues))
>
> # 3. Tampilkan Hasil
> print(wilks_lambda)
[1] 0.005149658
```

Mendekati 0: Menunjukkan bahwa varians dalam grup kecil dibandingkan varians antar grup. Artinya, fungsi sangat kuat dan hebat membedakan kelompok.

Uji Signifikansi Diskriminan

- Uji Hipotesis

```
> library(car)
> Anova(fit_lm, test="Wilks")
```

```
Type II MANOVA Tests: Wilks test statistic
  Df test stat approx F num Df den Df    Pr(>F)
y   2 0.0046028   2033.5      4    592 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Hipotesis Pengujian:

H_0 : Tidak ada perbedaan rata-rata skor diskriminan antar grup (Fungsi tidak signifikan).

H_1 : Minimal ada satu perbedaan rata-rata skor diskriminan antar grup (Fungsi signifikan).

TOLAK H_0 , Fungsi Signifikan

Evaluasi Model

- Hit Ratio (atau sering disebut Classification Accuracy) adalah persentase objek yang berhasil diklasifikasikan secara benar oleh model ke dalam grup asalnya.
- Alat Ukur: Confusion Matrix

Untuk menghitung Hit Ratio, kita menggunakan Confusion Matrix (Matriks Klasifikasi). Matriks ini membandingkan antara Grup Aktual (kenyataan di lapangan) dengan Grup Prediksi (hasil tebakan model).

- Rumus Hit Ratio

Dihitung dengan membagi jumlah total tebakan yang benar (angka di diagonal matriks) dengan jumlah seluruh sampel.

$$\text{Hit Ratio} = \left(\frac{\sum \text{Diagonal Confusion Matrix}}{N} \right) \times 100\%$$

- APER (Apparent Error Rate)

proporsi jumlah observasi yang salah diklasifikasikan oleh fungsi diskriminan

$$\text{APER} = 100\% - \text{Hit Ratio}$$

Evaluasi Model

```
> # 1. Melakukan Prediksi
> prediksi <- predict(model)
>
> # 2. Membuat Confusion Matrix
> tabel_akurasi <- table(Aktual = df_simulasi$y, Prediksi = prediksi$class)
> print(tabel_akurasi)
```

	Prediksi		
Aktual	1	2	3
1	100	0	0
2	0	100	0
3	0	0	100

```
> # Menghitung persentase akurasi
> akurasi <- sum(diag(tabel_akurasi)) / sum(tabel_akurasi)
> cat("Akurasi Total (Hit Ratio):", akurasi * 100, "%")
Akurasi Total (Hit Ratio): 100 %
```

Berapa nilai APER (Apparent Error Rate) ????

Terimakasih