

MODUL PRAKTIKUM
Analisis Multivariat

Modul 3: Multidimensional Scaling (MDS)



Penyusun:

Dr. Faula Arina, S.Si., M.Si.

Ferdian Bangkit Wijaya, S.Stat., M.Si.

LABORATORIUM STATISTIKA
PROGRAM STUDI STATISTIKA
FAKULTAS TEKNIK
UNIVERSITAS SULTAN AGENG TIRTAYASA
CILEGON
2026

HALAMAN PENGESAHAN

Nama Matakuliah : Analisis Multivariat
Kode/SKS : STA623208 /(2-1)
Nomor Modul : 3
Judul Modul : Multidimensional Scaling (MDS)
Pelaksanaan : Semester 4
Dosen Pengampu : Dr. Faula Arina, S.Si., M.Si.
Ferdian Bangkit Wijaya, S.Stat., M.Si.

Asisten Praktikum : Patricia Pingkan Kumenap
Rafi Ramadhan Asshiddieqie

Cilegon, 6 Maret 2026

Mengetahui,

Ketua Program Studi

Ketua Tim Penyusun Modul

Dr. Faula Arina, S.Si., M.Si.
NIP. 197112102005012002

Ferdian Bangkit Wijaya, S.Stat., M.Si.
NIP. 199005202024061001

KATA PENGANTAR

Alhamdulillahirabbil'aalamiin penulis panjatkan kepada Allah *subhanahu wa ta'ala* atas segala karunia-Nya sehingga Modul 3 Praktikum Mata Kuliah Analisis Multivariat dengan judul “**Multidimensional Scaling**” dapat diselesaikan. Shalawat dan salam semoga selalu terlimpah kepada Nabi Muhammad, keluarganya, dan para sahabatnya. Tujuan disusunnya modul praktikum ini adalah untuk membekali mahasiswa dalam penerapan teori yang telah dipelajari di perkuliahan dalam bentuk praktikum.

Kami mengucapkan terimakasih kepada semua pihak yang turut membantu proses penyusunan Modul Praktikum ini. Masukan dan Saran sangat diharapkan demi penyesuaian materi praktikum terhadap perkembangan keilmuan Statistika di masa yang akan datang.

Cilegon, Maret 2026

Tim Penyusun Modul Praktikum

DAFTAR ISI

KATA PENGANTAR.....	3
DAFTAR ISI.....	4
A. TUJUAN PRAKTIKUM.....	5
B. DASAR TEORI	5
1. Paket R yang Digunakan	6
2. Metric MDS: Principal Coordinates Analysis (PCoA)	6
3. Evaluasi Kecocokan (Goodness-of-Fit) PCoA	8
4. Interpretasi Peta Perseptual (Biplot).....	8
5. Non-Metric MDS (NMDS)	9
6. Algoritma Iteratif Non-Metric MDS (NMDS)	9
7. Evaluasi Kecocokan (Goodness-of-Fit) Non-Metric MDS (NMDS).....	10
C.DATA/SOAL/KASUS	11
1. Library R yang digunakan	11
2. Data Set	11
D.PENGOLAHAN DATA/ KASUS	12
1. Metric MDS (PCoA) dengan Jarak Euclidian	12
2. Non-Metric MDS (NMDS)	18
E. PENUGASAN	21
DAFTAR PUSTAKA	21

A. TUJUAN PRAKTIKUM

Setelah mengikuti praktikum ini, mahasiswa diharapkan mampu:

1. Memahami konsep dasar MDS dalam memvisualisasikan kemiripan atau ketidakmiripan antar objek ke dalam ruang berdimensi rendah.
2. Mengimplementasikan prosedur PCoA secara manual di R melalui tahapan pengolahan matriks, mulai dari double centering hingga dekomposisi eigen.
3. Memahami mekanisme iteratif NMDS yang berbasis pada urutan peringkat (rank-order) ketidakmiripan data.
4. Menghitung dan mengevaluasi nilai Stress sebagai ukuran kecocokan (goodness-of-fit) antara jarak pada peta dengan data asli. Menginterpretasikan metrik performa model
5. Melakukan interpretasi visual melalui Perceptual Map atau Biplot untuk mengungkap struktur dan hubungan antar objek.

B. DASAR TEORI

Multidimensional Scaling (MDS) merupakan teknik analisis multivariat yang digunakan untuk memvisualisasikan kemiripan atau ketidakmiripan antar objek. Tujuan utamanya adalah merepresentasikan objek-objek tersebut sebagai titik-titik dalam sebuah ruang berdimensi rendah (biasanya dua atau tiga dimensi) sedemikian rupa sehingga jarak antar titik mencerminkan hubungan kemiripan yang sebenarnya. Dengan MDS, pola tersembunyi atau pengelompokan yang tidak terlihat pada tabel data mentah dapat diungkap secara visual.

Data input utama dalam MDS berasal dari matriks proksimitas, yang dapat dibedakan menjadi dua jenis:

a. Matriks Kesamaan (Similarity Matrix)

Matriks ini berisi nilai yang menunjukkan tingkat kemiripan antar objek. Karakteristik utamanya adalah: Semakin besar nilai s_{ij} , semakin mirip hubungan antara objek-i dan objek-j. Diagonal utama berisi nilai maksimum karena objek paling mirip dengan dirinya sendiri. Matriks bersifat simetris ($s_{ij} = s_{ji}$).

b. Matriks Jarak (Dissimilarity Matrix)

Matriks ini sering disebut juga matriks ketidakmiripan. Karakteristik utamanya meliputi: Semakin besar nilainya, semakin tidak mirip atau semakin jauh jarak antar objek. Diagonal utama bernilai nol karena jarak objek ke dirinya sendiri adalah nol. Memenuhi kriteria non-negatif dan simetris. Untuk data metrik yang sesungguhnya, berlaku ketaksamaan segitiga (Triangle Inequality).

1. Paket R yang Digunakan

Berikut adalah daftar paket (library) R yang akan kita gunakan dalam praktikum ini:

- a. tidyverse: Kumpulan alat untuk manipulasi data (terutama dplyr) dan visualisasi (ggplot2).
- b. cluster: Digunakan untuk menghitung matriks ketidakmiripan (dissimilarity matrix), terutama fungsi daisy() yang mendukung perhitungan Jarak Gower untuk data dengan tipe campuran.
- c. MASS: Pustaka yang menyediakan fungsi isoMDS() untuk mengimplementasikan Non-Metric Multidimensional Scaling (NMDS) secara iteratif.
- d. vegan: Paket standar dalam analisis ekologi dan multivariat yang menyediakan fungsi wcmdscale() untuk PCoA dan metaMDS() untuk NMDS yang lebih stabil.
- e. factoextra: Digunakan untuk mengekstraksi dan memvisualisasikan hasil analisis multivariat agar menghasilkan perceptual map yang lebih informatif dan estetik.
- f. magrittr: Menyediakan operator pipe (%>%) untuk menyederhanakan penulisan kode R yang bersifat sekuensial.

2. Metric MDS: Principal Coordinates Analysis (PCoA)

Metric MDS, yang juga dikenal sebagai Principal Coordinates Analysis (PCoA), merupakan teknik yang mengasumsikan data masukan (ketidakmiripan) bersifat metrik, yaitu berskala interval atau rasio. Tujuan utamanya adalah menghasilkan sebuah peta spasial di mana jarak antar titik pada peta tersebut secara langsung proporsional dengan nilai ketidakmiripan pada data input asli.

Untuk merepresentasikan objek dalam ruang berdimensi rendah, algoritma PCoA melakukan tahapan dekomposisi matriks sebagai berikut:

- a. Kuadratkan Matriks Jarak ($D^{(2)}$) : Setiap elemen ketidakmiripan (d_{ij}) dalam matriks jarak asli dikuadratkan.

Jenis Jarak	Tipe Data Utama	Perlu Standarisasi?	Karakteristik & Kegunaan
Euclidean	Metrik (Interval/Rasio)	Wajib (Jika skala variabel berbeda)	Menghitung jarak garis lurus antar titik; sangat sensitif terhadap perbedaan satuan dan rentang data.
Manhattan	Metrik	Wajib (Jika skala variabel berbeda)	Menghitung jarak berdasarkan lintasan siku-siku (seperti blok jalan kota); lebih tahan (<i>robust</i>) terhadap pencilan (<i>outliers</i>) dibanding Euclidean.
Gower	Campuran (Nominal, Ordinal, Metrik)	Tidak Perlu	Melakukan normalisasi internal secara otomatis dengan membagi selisih absolut dengan rentang variabel. Sangat fleksibel untuk data survei.
Bray-Curtis	Rasio / Cacahan (<i>Counts</i>)	Tidak Perlu (Biasanya)	Umum digunakan dalam ekologi; tidak terpengaruh oleh jumlah nol yang banyak pada data (masalah <i>double zero</i>).
Maximum	Metrik	Wajib	Hanya mengambil selisih terbesar di antara semua koordinat variabel; berguna untuk kasus koordinasi ekstrem.

- b. Hitung Matriks Skalar Produk (S): Melakukan proses double centering pada matriks $-1/2D^{(2)}$. Elemen S_{ij} dihitung dengan formula:

$$S_{ij} = -\frac{1}{2} \left(d_{ij}^2 - \overline{d_{i.}^{(2)}} - \overline{d_{.j}^{(2)}} + \overline{d_{..}^{(2)}} \right)$$

Keterangan:

$\overline{d_{i.}^{(2)}}$ adalah rata-rata baris ke-i,

$\overline{d_{.j}^{(2)}}$ adalah rata-rata kolom ke-j, dan

$\overline{d_{..}^{(2)}}$ adalah rata-rata keseluruhan dari matriks jarak kuadrat.

- c. Dekomposisi Eigen: Mencari nilai eigenvalues (λ) dan eigenvectors (V) dari matriks S sehingga memenuhi persamaan $SV = V\Lambda$.

- d. Penentuan Koordinat Baru (X_{new}): Setelah menentukan jumlah dimensi k yang diinginkan (biasanya $k=2$ atau $k=3$), koordinat baru dihitung sebagai: $X_{new} = V_k \Lambda_k^{1/2}$. Di mana V_k adalah matriks eigenvectors dan Λ_k adalah matriks diagonal eigenvalues yang bersesuaian dengan k dimensi yang dipilih.

3. Evaluasi Kecocokan (Goodness-of-Fit) PCoA

Kualitas hasil pemetaan PCoA dievaluasi menggunakan dua ukuran utama:

- a. Proporsi Varians: Menunjukkan seberapa besar informasi dari data asli yang berhasil dijelaskan oleh k dimensi yang dipilih.

$$\text{Proporsi Varians} = \frac{\sum_{i=1}^k \lambda_i}{\sum \text{semua } \lambda \text{ positif}}$$

- b. Stress-1: Ukuran ketidakcocokan antara jarak pada peta ($\widehat{d}_{ij}$) dengan jarak asli (d_{ij}). Nilai Stress yang rendah (mendekati 0) menunjukkan kecocokan yang sangat baik.

Ukuran Evaluasi	Nilai Ideal	Kategori Interpretasi
Proporsi Varians	> 70% atau 80%	Semakin tinggi semakin baik, karena artinya informasi yang hilang akibat reduksi sangat sedikit.
Stress-1	< 20%	Cukup (<i>Fair</i>); peta masih bisa diinterpretasikan.
	< 10%	Bagus (<i>Good</i>); representasi jarak pada peta sangat akurat.
	< 5%	Sangat Bagus (<i>Excellent</i>); nyaris tidak ada distorsi.
	0%	Sempurna; jarak di peta identik dengan jarak asli (jarang terjadi di data riil).

4. Interpretasi Peta Perseptual (Biplot)

Dalam menginterpretasikan hasil PCoA melalui biplot, hal-hal berikut perlu diperhatikan:

- a. Sebaran Objek: Kedekatan antar titik (objek) menunjukkan tingkat kemiripan; semakin dekat posisi dua titik, semakin mirip karakteristik objek tersebut.
- b. Arah Panah (Variabel): Menunjukkan arah di mana nilai variabel tersebut meningkat dalam peta.
- c. Panjang Panah: Mengindikasikan seberapa kuat pengaruh variabel tersebut dalam menjelaskan sebaran objek. Panah yang lebih panjang menunjukkan pengaruh yang lebih dominan.
- d. Sudut Antar Panah: Sudut sempit menunjukkan korelasi positif kuat, sudut mendekati 180° menunjukkan korelasi negatif, dan sudut mendekati 90° menunjukkan variabel yang kurang berkorelasi.

5. Non-Metric MDS (NMDS)

Non-Metric MDS (NMDS) digunakan ketika data input bersifat ordinal, di mana nilai absolut ketidakmiripan tidak dianggap sepenting urutan peringkatnya (rank-order). Berbeda dengan PCoA yang bersifat analitis (sekali hitung), NMDS merupakan prosedur berbasis algoritma iteratif yang mencoba menemukan konfigurasi titik terbaik untuk mempertahankan urutan jarak objek.

Karakteristik NMDS :

- a. Fokus pada Peringkat: NMDS berupaya menghasilkan peta di mana urutan jarak antar titik ($\widehat{d}_{ij}$) sedekat mungkin dengan urutan ketidakmiripan aslinya (d_{ij}).
- b. Fleksibilitas: NMDS lebih fleksibel dan sering kali lebih robust (tangguh) ketika asumsi metrik (skala interval/rasio) tidak terpenuhi.
- c. Non-Linear: Hubungan antara jarak pada peta dan jarak asli tidak harus linear, melainkan cukup bersifat monotonik (searah).

6. Algoritma Iteratif Non-Metric MDS (NMDS)

Proses pencarian koordinat dalam NMDS dilakukan melalui langkah-langkah berikut:

- a. Konfigurasi Awal: Menempatkan titik-titik secara acak (atau berdasarkan tebakan awal) dalam dimensi yang diinginkan (misal 2D).
- b. Perhitungan Jarak Peta: Menghitung jarak antar titik ($\widehat{d}_{ij}$) dalam konfigurasi saat ini.

- c. Perbandingan Urutan: Membandingkan urutan peringkat jarak pada peta dengan urutan peringkat ketidakmiripan data asli.
- d. Evaluasi Stress: Menghitung nilai Stress untuk mengukur sejauh mana ketidakcocokan antara kedua urutan tersebut.
- e. Optimasi (Pergeseran Titik): Menggeser posisi titik secara bertahap untuk mengurangi nilai Stress.
- f. Konvergensi: Mengulangi proses hingga nilai Stress tidak dapat dikurangi lagi secara signifikan atau mencapai batas iterasi maksimum.

Misalkan terdapat 3 objek (A, B, C) dengan urutan ketidakmiripan asli: $d_{AB} < d_{BC} < d_{AC}$.

- a. Jika pada konfigurasi awal jarak pada peta menunjukkan A dan C paling dekat, maka algoritma akan mendeteksi Stress yang tinggi karena menyalahi urutan target.
- b. Algoritma kemudian akan menjauhkan titik A dan C, serta mendekatkan titik A dan B hingga urutan jaraknya sesuai dengan data asli.

7. Evaluasi Kecocokan (Goodness-of-Fit) Non-Metric MDS (NMDS)

Kualitas hasil NMDS dinilai berdasarkan seberapa kecil nilai *Stress*-nya. Secara matematis, *Stress-1* didefinisikan sebagai:

$$\text{Stress} = \sqrt{\frac{\sum (d_{ij} - \widehat{d}_{ij})^2}{\sum d_{ij}^2}}$$

Berdasarkan nilai yang dihasilkan:

- Stress < 5%: Representasi sangat sempurna (*Excellent*).
- 5% - 10%: Representasi baik (*Good*).
- 10% - 20%: Representasi cukup (*Fair*).
- > 20%: Representasi buruk, peta sulit dipercaya.

C.DATA/SOAL/KASUS

1. Library R yang digunakan

```
library(tidyverse) # Manipulasi data & ggplot2
library(cluster) # Perhitungan Jarak Gower (daisy)
library(MASS) # Fungsi isoMDS untuk Non-Metric MDS
library(vegan) # Fungsi metaMDS & wcmdscale (standar ekologi)
library(factoextra) # Visualisasi MDS yang estetik
library(magrittr) # Operator pipe ( %>% )
```

2. Data Set

Dalam praktikum ini, kita akan menggunakan dua kumpulan data (dataset) dari library dasar R:

- a. USArrests: Data ini berisi statistik penangkapan per 100.000 penduduk untuk kasus pembunuhan (Murder), penyerangan (Assault), dan pemerkosaan (Rape) di masing-masing dari 50 negara bagian Amerika Serikat pada tahun 1973. Selain variabel kriminalitas, terdapat variabel UrbanPop yang menunjukkan persentase penduduk yang tinggal di daerah perkotaan. Karena data ini bersifat metrik dan kontinu, kita akan mengolahnya terlebih dahulu menjadi matriks ketidakmiripan melalui perhitungan jarak Euclidean sebelum melakukan prosedur dekomposisi matriks.
- b. eurodist: Merupakan matriks ketidakmiripan (dissimilarity matrix) yang sudah jadi, berisi data jarak jalan raya dalam satuan kilometer antar 21 kota besar di Eropa. Data ini disimpan dalam format objek kelas dist yang membentuk matriks segitiga bawah. Karena input sudah berbentuk jarak, kita dapat langsung menerapkan algoritma NMDS untuk menguji konsistensi urutan peringkat (rank-order) dan melihat apakah konfigurasi titik yang dihasilkan mampu merekonstruksi peta lokasi geografis kota-kota tersebut secara akurat..

```
# Persiapan Data
# Memanggil data untuk Kasus 1 (PCoA)
data("USArrests")
head(USArrests)

# Memanggil data untuk Kasus 2 (NMDS)
data("eurodist")
# eurodist sudah berbentuk matriks jarak (dist)
print(as.matrix(eurodist)[1:5, 1:5])
```

D.PENGOLAHAN DATA/ KASUS

1. Metric MDS (PCoA) dengan Jarak Euclidian

```
# A. Persiapan Data
data("USArrests")
# Standarisasi data agar mean=0 dan sd=1
df_scaled <- scale(USArrests)
head(df_scaled)
```

```
> head(df_scaled)
```

	Murder	Assault	UrbanPop	Rape
Alabama	1.24256408	0.7828393	-0.5209066	-0.003416473
Alaska	0.50786248	1.1068225	-1.2117642	2.484202941
Arizona	0.07163341	1.4788032	0.9989801	1.042878388
Arkansas	0.23234938	0.2308680	-1.0735927	-0.184916602
California	0.27826823	1.2628144	1.7589234	2.067820292
Colorado	0.02571456	0.3988593	0.8608085	1.864967207

```
# B. Menghitung Matriks Jarak (Euclidean)
D <- as.matrix(dist(df_scaled, method = "euclidean"))
head(D)
```

```
> head(D)
```

	Alabama	Alaska	Arizona	Arkansas	California	Colorado
Alabama	0.000000	2.703754	2.293520	1.289810	3.263110	2.651067
Alaska	2.703754	0.000000	2.700643	2.826039	3.012541	2.326519
Arizona	2.293520	2.700643	0.000000	2.717758	1.310484	1.365031
Arkansas	1.289810	2.826039	2.717758	0.000000	3.763641	2.831051
California	3.263110	3.012541	1.310484	3.763641	0.000000	1.287619
Colorado	2.651067	2.326519	1.365031	2.831051	1.287619	0.000000

	Connecticut	Delaware	Florida	Georgia	Hawaii	Idaho
Alabama	3.215297	2.019293	2.298135	1.131435	3.388530	2.914662
Alaska	4.739912	3.621363	2.996764	2.819439	4.530134	4.058055
Arizona	3.262858	1.909370	1.749393	2.787196	3.262121	3.521007
Arkansas	2.607639	1.800324	3.372197	2.211761	2.972310	1.768726
California	4.066390	3.073785	2.025004	3.378058	3.658908	4.487944
Colorado	3.327992	2.554746	2.445860	2.864910	2.823352	3.476768

```
# C. Prosedur PCoA Manual (Sesuai Teori)
# 1. Kuadratkan Matriks Jarak
D2 <- D^2
head(D2)
```

```
> head(D2)
```

	Alabama	Alaska	Arizona	Arkansas	California	Colorado
Alabama	0.000000	7.310286	5.260233	1.663610	10.647889	7.028158
Alaska	7.310286	0.000000	7.293472	7.986494	9.075406	5.412689
Arizona	5.260233	7.293472	0.000000	7.386210	1.717369	1.863309
Arkansas	1.663610	7.986494	7.386210	0.000000	14.164993	8.014851
California	10.647889	9.075406	1.717369	14.164993	0.000000	1.657961
Colorado	7.028158	5.412689	1.863309	8.014851	1.657961	0.000000

	Connecticut	Delaware	Florida	Georgia	Hawaii	Idaho
Alabama	10.338138	4.077543	5.281426	1.280145	11.482136	8.495257
Alaska	22.466770	13.114272	8.980595	7.949235	20.522114	16.467814
Arizona	10.646239	3.645692	3.060375	7.768463	10.641432	12.397491
Arkansas	6.799784	3.241166	11.371711	4.891889	8.834625	3.128390
California	16.535526	9.448155	4.100641	11.411279	13.387610	20.141637
Colorado	11.075531	6.526725	5.982231	8.207712	7.971319	12.087919

```
# 2. Double Centering untuk mendapatkan Matriks Skalar Produk (S)
n <- nrow(D2)
J <- diag(n) - (1/n) * matrix(1, n, n)
S <- -0.5 * J %*% D2 %*% J
head(S)
```

```
> head(S)
```

	[,1]	[,2]	[,3]	[,4]	[,5]	[,6]
[1,]	2.4281583	2.120245	0.7227361	1.0293148	0.4110474	-0.1105777
[2,]	2.1202447	9.122617	3.0533459	1.2151022	4.5445183	4.0443860
[3,]	0.7227361	3.053346	4.2775468	-0.9072909	5.8010018	3.3965410
[4,]	1.0293148	1.215102	-0.9072909	1.2940817	-1.9145427	-1.1709625
[5,]	0.4110474	4.544518	5.8010018	-1.9145427	9.0418257	5.8813541
[6,]	-0.1105777	4.044386	3.3965410	-1.1709625	5.8813541	4.3788440

```
# 3. Dekomposisi Eigen
eigen_S <- eigen(S)
lambda <- eigen_S$values
V <- eigen_S$vectors
lambda
V
```

```
> lambda
[1] 1.215318e+02 4.849849e+01 1.747160e+01 8.498074e+00 8.931745e-15
[6] 7.106121e-15 6.601605e-15 3.817095e-15 3.598192e-15 3.587554e-15
[11] 3.107468e-15 2.948981e-15 2.876087e-15 2.755053e-15 2.593014e-15
[16] 2.477204e-15 2.453187e-15 1.509207e-15 1.095539e-15 9.950583e-16
[21] 9.874437e-16 8.948449e-16 8.831817e-16 6.637460e-16 3.198458e-16
[26] 2.969245e-16 2.238012e-16 -1.651586e-16 -2.974504e-16 -4.695417e-16
[31] -4.795996e-16 -5.399372e-16 -5.444454e-16 -6.420983e-16 -8.279767e-16
[36] -9.007989e-16 -9.495253e-16 -1.474942e-15 -1.475707e-15 -2.139890e-15
[41] -2.261752e-15 -3.004183e-15 -3.993358e-15 -4.026943e-15 -4.178312e-15
[46] -4.497984e-15 -5.500937e-15 -7.793586e-15 -1.004827e-14 -1.108789e-14
> V
      [,1]      [,2]      [,3]      [,4]      [,5]
[1,] -0.088502119 0.16111249 0.105218608 -0.0530665011 0.0000000000
[2,] -0.175119011 0.15255799 -0.483145153 0.1489378244 -0.0072855922
[3,] -0.158329049 -0.10603826 -0.012974042 0.2834384049 -0.1395789998
[4,] 0.012699298 0.15917987 -0.027135114 0.0620804497 -0.2363621319
[5,] -0.226649068 -0.21932910 -0.141759482 0.1161380178 -0.1306254342
```

```
# 4. Ekstraksi Koordinat Baru (k=2 dimensi)[cite: 3]
k <- 2
X_new <- V[, 1:k] %*% diag(sqrt(lambda[1:k]))
colnames(X_new) <- c("PCo1", "PCo2")
rownames(X_new) <- rownames(USArrests)
head(X_new)
```

```
> head(X_new)
      PCo1      PCo2
Alabama -0.9756604 1.1220012
Alaska -1.9305379 1.0624269
Arizona -1.7454429 -0.7384595
Arkansas 0.1399989 1.1085423
California -2.4986128 -1.5274267
Colorado -1.4993407 -0.9776297
```

```

# D. Evaluasi Goodness-of-Fit PCoA
# A. Menghitung Proporsi Varians (Berdasarkan Eigenvalue)
# Hanya gunakan eigenvalue yang bernilai positif
lambda_pos <- lambda[lambda > 0]
prop_var <- sum(lambda[1:k]) / sum(lambda_pos)

cat("Proporsi Varians (k=2):", round(prop_var * 100, 2), "%\n")

# B. Menghitung Stress-1 (Kruskal's Stress)
# 1. Hitung jarak pada peta (distance in reduced space)
D_map <- as.matrix(dist(X_new, method = "euclidean"))

# 2. Hitung Stress-1 menggunakan rumus manual:
# Stress = sqrt( sum( (d_ij - d_hat_ij)^2 ) / sum( d_ij^2 ) )
numerator <- sum((D - D_map)^2)
denominator <- sum(D^2)
stress_1 <- sqrt(numerator / denominator)

cat("Nilai Stress-1 PCoA:", round(stress_1 * 100, 2), "%\n")

```

```

> cat("Proporsi Varians (k=2):", round(prop_var * 100, 2), "%\n")
Proporsi Varians (k=2): 86.75 %

```

```

> cat("Nilai Stress-1 PCoA:", round(stress_1 * 100, 2), "%\n")
Nilai Stress-1 PCoA: 13.42 %

```

Hasil tersebut menunjukkan bahwa penggunaan dua dimensi (k=2) dalam PCoA sudah sangat representatif karena mampu menjelaskan 86,75% variabilitas dari data asli, yang berarti hanya sedikit informasi yang terbuang saat proses reduksi dimensi. Sementara itu, nilai Stress-1 sebesar 13,42% mengindikasikan tingkat kecocokan yang berada pada kategori cukup baik (*fair to good*) dalam mempertahankan proporsi jarak antar objek, sehingga peta perseptual yang dihasilkan memiliki tingkat akurasi yang memadai untuk menginterpretasikan kemiripan antar negara bagian.

```

# D. Visualisasi Perceptual Map
loadings <- cor(df_scaled, X_new)
scale_arrow <- 2 # Skala arrow


# 5. Visualisasi Biplot
# Tentukan batas agar semua panah dan titik terlihat
plot(X_new[,1], X_new[,2], pch=19, col="darkblue",
     xlim=c(-3.5, 3.5), ylim=c(-3.5, 3.5), # Memperluas kanvas
     xlab="Principal Coordinate 1", ylab="Principal Coordinate 2",
     main="PCoA Manual Biplot: USArrests Data")

# Tambahkan Panah Variabel
arrows(0, 0,
      loadings[,1] * scale_arrow,
      loadings[,2] * scale_arrow,
      col="red", lwd=2, length=0.1)

# Tambahkan Label Variabel (Murder, Assault, UrbanPop, Rape)
text(loadings[,1] * scale_arrow,
     loadings[,2] * scale_arrow,
     labels=colnames(USArrests),
     col="red", pos=3, font=2)

# Tambahkan Nama Negara Bagian
text(X_new[,1], X_new[,2], labels=rownames(X_new), pos=3, cex=0.7)
abline(h=0, v=0, lty=2, col="gray")

```



Interpretasi Biplot :

1. Sebaran Objek (Analisis Proksimitas)

- Kedekatan Antar Objek: Kedekatan posisi antar negara bagian menunjukkan kemiripan profil kriminalitas. Sebagai contoh, Mississippi, North Carolina, dan South Carolina yang mengelompok di bagian atas menunjukkan bahwa ketiga wilayah tersebut memiliki karakteristik angka kejahatan yang sangat serupa.
- Posisi Terhadap Panah: Negara bagian yang berada di sisi kiri (seperti California, Nevada, dan Florida) terletak searah dengan mayoritas panah kejahatan. Hal ini menandakan wilayah-wilayah tersebut memiliki angka penangkapan kasus *Murder*, *Assault*, dan *Rape* yang jauh lebih tinggi dibandingkan rata-rata nasional.
- Objek Ekstrem: Negara bagian seperti North Dakota, Vermont, dan Maine berada di posisi yang berlawanan arah dengan semua panah kejahatan, mengindikasikan bahwa wilayah ini adalah wilayah dengan tingkat kriminalitas terendah dalam dataset.

2. Arah dan Panjang Panah (Vektor Variabel)

- Arah Pertumbuhan: Panah menunjukkan arah peningkatan nilai suatu variabel. Semakin suatu objek bergerak mengikuti arah panah *Murder*, maka angka pembunuhan di wilayah tersebut semakin tinggi.
- Panjang Panah (Kepentingan): Panjang panah merepresentasikan varians variabel yang berhasil dijelaskan oleh koordinat utama. Panah *Assault* dan *Murder* yang terlihat panjang menunjukkan bahwa kedua variabel ini memiliki pengaruh paling dominan dalam membedakan karakteristik antar negara bagian di Amerika Serikat.

3. Analisis Sudut (Korelasi Antar Variabel)

Sudut antara dua panah adalah representasi visual dari nilai korelasi (cosinus sudut):

- Sudut Sempit ($< 90^\circ$): Panah *Murder* dan *Assault* membentuk sudut yang sangat sempit (mendekati 0°), menunjukkan korelasi positif yang sangat kuat. Secara praktis, jika angka pembunuhan di suatu wilayah tinggi, maka hampir dipastikan angka penyerangan di wilayah tersebut juga tinggi.
- Sudut Siku-Siku ($\approx 90^\circ$): Panah *UrbanPop* (penduduk perkotaan) membentuk sudut yang hampir tegak lurus terhadap variabel *Murder* dan *Assault*. Hal ini secara matematis menunjukkan bahwa kedua variabel tersebut tidak berkorelasi. Artinya, tinggi rendahnya persentase penduduk kota di suatu negara bagian tidak menjamin tinggi rendahnya angka pembunuhan di wilayah tersebut.

- Sudut Tumpul ($> 90^\circ$): Menunjukkan korelasi negatif. Objek yang berada di sisi kanan peta (berlawanan dengan arah panah) memiliki korelasi negatif terhadap variabel kejahatan tersebut.

4. Interpretasi Sumbu (Dimension Meaning)

- Principal Coordinate 1 (Horizontal): Sumbu ini dapat diinterpretasikan sebagai "Indeks Kriminalitas Umum". Semakin ke kiri koordinat suatu negara bagian, semakin tinggi beban kejahatannya.
- Principal Coordinate 2 (Vertikal): Sumbu ini lebih banyak dipengaruhi oleh faktor demografi, khususnya Tingkat Urbanisasi. Wilayah di bagian bawah peta (seperti New Jersey dan Massachusetts) merupakan wilayah dengan populasi perkotaan yang tinggi, sementara wilayah di bagian atas cenderung lebih rural.

2. Non-Metric MDS (NMDS)

```
# A. Persiapan Library dan Data
library(MASS)
data("eurodist")
eurodist
```

```
> eurodist
```

	Athens	Barcelona	Brussels	Calais	Cherbourg	Cologne
Barcelona	3313					
Brussels	2963	1318				
Calais	3175	1326	204			
Cherbourg	3339	1294	583	460		
Cologne	2762	1498	206	409	785	
Copenhagen	3276	2218	966	1136	1545	760
Geneva	2610	803	677	747	853	1662
Gibraltar	4485	1172	2256	2224	2047	2436
Hamburg	2977	2018	597	714	1115	460
Hook of Holland	3030	1490	172	330	731	269
Lisbon	4532	1305	2084	2052	1827	2290
Lyons	2753	645	690	739	789	714
Madrid	3949	636	1558	1550	1347	1764
Marseille	3865	531	1011	1050	1101	1035

```
# B. Menjalankan Algoritma NMDS
# isoMDS menggunakan prosedur iteratif untuk meminimalkan Stress
set.seed(123) # Menjamin hasil iterasi konsisten
nmds_result <- isoMDS(eurodist, k = 2)
```


```
> nmds_result <- isoMDS(eurodist, k = 2)
initial value 7.505733
final value 7.505688
converged
```

```
# C. Ekstraksi Hasil dan Nilai Stress
points <- nmds_result$points
colnames(points) <- c("Dimensi 1", "Dimensi 2")
stress_val <- nmds_result$stress
stress_val
```

```
> stress_val
[1] 7.505688
```

```
# D. Visualisasi Peta Rekonstruksi
# Kita kalikan -1 pada sumbu y agar orientasi peta lebih mirip
geografis aslinya
plot(points[,1], -points[,2], type="n", asp=1,
      xlab="Dimensi 1", ylab="Dimensi 2",
      main="NMDS: Rekonstruksi Peta Kota-Kota di Eropa")
text(points[,1], -points[,2], labels=labels(eurodist),
      cex=0.8, col="darkred", font=2)
abline(h=0, v=0, lty=2, col="gray")
```

NMDS: Rekonstruksi Peta Kota-Kota di Eropa



Interpretasi :

1. Rekonstruksi Geografis (Posisi Relatif)

Meskipun hanya menggunakan input matriks jarak antar kota, algoritma NMDS berhasil merekonstruksi konfigurasi spasial kota-kota tersebut sehingga menyerupai peta asli Eropa.

Kelompok Utara: Kota-kota seperti Stockholm, Copenhagen, dan Hamburg berada di bagian atas peta, mencerminkan posisi geografis mereka di wilayah Utara.

Klaster Eropa Barat: Terlihat penumpukan teks di tengah yang mencakup Paris, Brussels, Calais, dan Cologne. Kedekatan posisi teks ini menunjukkan bahwa kota-kota tersebut memang memiliki jarak tempuh yang sangat pendek satu sama lain.

Semenanjung Iberia: Di sisi kiri (Barat), kita melihat Lisbon, Madrid, dan Gibraltar mengelompok bersama, sesuai dengan letak mereka di ujung Barat Eropa.

Eropa Selatan/Tenggara: Rome dan Athens berada di bagian bawah dan cenderung ke kanan, merepresentasikan wilayah Selatan dan Tenggara yang lebih jauh dari pusat klaster Eropa Barat.

2. Efek Refleksi (Sumbu Dimensi 2)

Penggunaan nilai negatif pada Dimensi 2 (-points[,2]) terbukti efektif. Tanpa refleksi ini, kota Stockholm mungkin akan berada di posisi paling bawah peta karena algoritma MDS tidak mengenal orientasi kompas (Utara/Selatan), melainkan hanya menjaga jarak antar titik. Dengan refleksi ini, kita mendapatkan representasi yang intuitif di mana:

Dimensi 1 (Horizontal): Bertindak secara kasar sebagai sumbu Barat - Timur.

Dimensi 2 (Vertikal): Bertindak secara kasar sebagai sumbu Selatan - Utara.

3. Skala dan Satuan

Perlu ditekankan bahwa angka pada sumbu Dimensi 1 dan Dimensi 2 (rentang -2000 hingga 2000) bukanlah satuan kilometer, melainkan koordinat arbiter dalam ruang dua dimensi yang meminimalkan nilai Stress. Yang paling penting dalam interpretasi ini bukanlah nilai koordinat absolutnya, melainkan jarak relatif antar kota di dalam bidang tersebut.

E. PENUGASAN

A. Dalam modul, kita telah mempelajari bahwa Jarak Euclidean memerlukan standarisasi, sedangkan Jarak Gower tidak.

1. Gunakan kembali dataset USArrests. Lakukan PCoA menggunakan Jarak Gower (menggunakan fungsi daisy dari library cluster).
2. Bandingkan peta perseptual yang dihasilkan dari Jarak Gower dengan peta dari Jarak Euclidean (yang sudah distandarkan) pada bagian praktikum sebelumnya.
3. Analisis: Apakah terdapat perbedaan posisi yang signifikan pada negara bagian tertentu? Mengapa hal tersebut bisa terjadi?

B. Gunakan dataset eurodist.

1. Lakukan prosedur NMDS dengan $k=3$.
2. Bandingkan nilai Stress yang didapat antara $k=2$ (pada praktikum) dengan $k=3$.
3. Analisis: Mengapa penambahan dimensi (k) cenderung menurunkan nilai Stress? Apa konsekuensi negatif jika kita menggunakan nilai k yang terlalu besar (misalnya $k=10$) dalam konteks visualisasi data?

DAFTAR PUSTAKA

Joseph F. Hair, Jr., Rolph E. Anderson, Ronald L. Tatham and William C. black, 2014. "Multivariate Data Analysis", Prentice Hall.

Sharma, Subbash, 1996, "Applied Multivariate Techniques", John Wiley & Sons.

Johnson, A. Richard and Wichern W. Dean, " Applied Multivariate Statistical Analysis", Upper Saddle River, Prentice Hall

Santoso Singgih, (2002), "SPSS Statistik Multivariat", Gramedia

Ronald E Walpole, Raymond H. Myers, Sharon L. Myers, and Keying Ye, 2002, "Probability and Statistics for Engineers and Scientists, Ninth Edition," Prentice-Hall, USA
James, G, D Witten, T Hastie, and R Tibshirani. 2013. An Introduction to Statistical Learning with Applications in R. Sixth. New York: Springer.