

Multidimensional Scaling (MDS)

Ferdian Bangkit Wijaya, S.Stat., M.Si.

Definisi

- Teknik analisis multivariat yang digunakan untuk memvisualisasikan kemiripan atau ketidakmiripan antar objek
- Tujuan utamanya adalah untuk merepresentasikan objek-objek tersebut sebagai titik-titik dalam sebuah ruang berdimensi rendah (biasanya dua atau tiga dimensi) sedemikian rupa sehingga jarak antar titik dalam peta tersebut mencerminkan kemiripan (atau ketidakmiripan) antar objek yang sebenarnya.

Konsep Dasar

MDS bekerja dengan data yang merepresentasikan proksimitas (kedekatan atau jarak) antar pasangan objek. Proksimitas ini bisa berasal dari:

1. Data primer: Penilaian subjektif responden mengenai kemiripan antar objek (misalnya, seberapa mirip merek A dengan merek B).
2. Data sekunder: Dihitung dari data atribut multivariat. Misalnya, jika Anda memiliki data beberapa variabel (atribut) untuk sejumlah objek, Dapat dihitung dari matriks jarak (seperti jarak Euklidian) antar semua pasangan objek berdasarkan atribut-atribut tersebut.

Kegunaan MDS

- Reduksi Dimensi: Menyederhanakan data dengan banyak variabel menjadi representasi visual berdimensi lebih rendah.
- Visualisasi Struktur Data: Mengungkap pola tersembunyi, pengelompokan (klaster), atau hubungan antar objek yang mungkin tidak terlihat dari tabel data mentah.
- Pemetaan Perseptual: Sering digunakan dalam riset pasar untuk memahami bagaimana konsumen memandang berbagai merek atau produk relatif satu sama lain berdasarkan atribut tertentu.
- Analisis Perbandingan: Membandingkan kemiripan antar individu, produk, lokasi geografis, atau unit observasi lainnya berdasarkan serangkaian karakteristik.

Matriks Kesamaan (Kemiripan / Similarity Matrix)

Definisi :

Matriks kesamaan adalah matriks persegi ($N \times N$) yang setiap elemennya (s_{ij}) merepresentasikan tingkat kemiripan atau kedekatan antara objek i dan objek j .

Matriks Kesamaan (Kemiripan / Similarity Matrix)

Karakteristik:

- Nilai Lebih Besar, Lebih Mirip: Semakin besar nilai s_{ij} , semakin mirip atau semakin dekat hubungan antara objek i dan objek j.
- Diagonal Maksimum: Kemiripan sebuah objek dengan dirinya sendiri (s_{ii}) biasanya memiliki nilai maksimum dalam matriks tersebut (tergantung skala yang digunakan : misalnya, 1 jika dinormalisasi).
- Simetris: Kemiripan objek i dengan objek j sama dengan kemiripan objek j dengan objek i ($s_{ij} = s_{ji}$).

Matriks Kesamaan (Kemiripan / Similarity Matrix)

- Cara Memperoleh Matriks Kesamaan:
- Data Primer :
 - Penilaian Subjektif Langsung: Responden diminta secara langsung untuk menilai seberapa "mirip" pasangan objek. Misalnya, "Pada skala 1 sampai 10, seberapa miripkah merek A dengan merek B?"
- Data Sekunder :
 - Koefisien Korelasi: Jika objek adalah variabel, koefisien korelasi antar variabel dapat dianggap sebagai ukuran kemiripan. Nilai korelasi yang tinggi menunjukkan kemiripan yang tinggi.
 - Indeks Kemiripan: Berbagai indeks kemiripan dapat dihitung dari data atribut, untuk data kategorikal atau biner (misalnya, koefisien Jaccard, koefisien Dice) atau data numerik (misalnya, Cosine Similarity).
 - Frekuensi Interaksi atau Ko-okurensi: Frekuensi di mana dua item muncul bersamaan bisa menjadi ukuran kemiripan. Misalnya, berapa kali dua produk dibeli bersamaan, atau dua kata muncul dalam dokumen yang sama

Contoh Cosine Similarity

Objek	Atribut X1	Atribut X2	Atribut X3	Vektor
A	1	2	3	(1, 2, 3)
B	2	4	6	(2, 4, 6)
C	5	1	1	(5, 1, 1)

rumus untuk Kosinus Kemiripan (Cosine Similarity)

$$S_{PQ} = \frac{\sum_{k=1}^p P_k Q_k}{\sqrt{\sum_{k=1}^p P_k^2} \sqrt{\sum_{k=1}^p Q_k^2}}$$

- Jika sudutnya 0° (vektor searah), kosinusnya 1 (kemiripan sempurna).
- Jika sudutnya 90° (vektor ortogonal), kosinusnya 0 (tidak ada kemiripan).
- Jika sudutnya 180° (vektor berlawanan arah), kosinusnya -1 (ketidakmiripan sempurna atau arah berlawanan).

kemiripan antara Objek A dan Objek C.

- Objek A (P dalam rumus): Vektor atribut $A = (P_1, P_2, P_3) = (1, 2, 3)$
- Objek C (Q dalam rumus): Vektor atribut $C = (Q_1, Q_2, Q_3) = (5, 1, 1)$

1. Hitung Product Dot ($A \cdot C = \sum_{k=1}^3 A_k C_k$):

$$A \cdot C = (A_1 \times C_1) + (A_2 \times C_2) + (A_3 \times C_3)$$

$$A \cdot C = (1 \times 5) + (2 \times 1) + (3 \times 1)$$

$$A \cdot C = 5 + 2 + 3$$

$$A \cdot C = 10$$

2. Hitung Magnitudo Objek A ($\|A\| = \sqrt{\sum_{k=1}^3 A_k^2}$): 3. Hitung Magnitudo Objek C ($\|C\| = \sqrt{\sum_{k=1}^3 C_k^2}$):

$$\|A\| = \sqrt{A_1^2 + A_2^2 + A_3^2}$$

$$\|A\| = \sqrt{1^2 + 2^2 + 3^2}$$

$$\|A\| = \sqrt{1 + 4 + 9}$$

$$\|A\| = \sqrt{14} \approx 3.742$$

$$\|C\| = \sqrt{C_1^2 + C_2^2 + C_3^2}$$

$$\|C\| = \sqrt{5^2 + 1^2 + 1^2}$$

$$\|C\| = \sqrt{25 + 1 + 1}$$

$$\|C\| = \sqrt{27} \approx 5.196$$

4. Masukkan nilai-nilai ke dalam rumus S_{AC} :

$$S_{AC} = \frac{A \cdot C}{\|A\| \cdot \|C\|}$$

$$S_{AC} = \frac{10}{(\sqrt{14}) \cdot (\sqrt{27})}$$

nilai kosinus kemiripan sekitar 0.514 $S_{AC} \approx 0.514$

Contoh Cosine Similarity

Interpretasi matrix

Susun Matriks Kesamaan (S)

	A	B	C
A	1.000	1.000	0.514
B	1.000	1.000	0.514
C	0.514	0.514	1.000

- Objek A dan B sangat mirip (nilai 1.000) karena profil atribut mereka proporsional.
- Objek A dan C memiliki tingkat kemiripan sedang (0.514), begitu juga B dan C.
- Diagonalnya berisi 1, menunjukkan kemiripan sempurna objek dengan dirinya sendiri.
- Matriksnya simetris ($S_{ij} = S_{ji}$).

Matriks Jarak (Ketidakmiripan / Dissimilarity Matrix)

Definisi :

Matriks jarak, atau sering juga disebut matriks ketidakmiripan, adalah sebuah matriks persegi ($N \times N$, di mana N adalah jumlah objek) yang setiap elemennya (d_{ij}) merepresentasikan tingkat ketidakmiripan atau jarak antara objek i dan objek j .

Matriks Jarak (Ketidakmiripan / Dissimilarity Matrix)

Karakteristik :

- Nilai Lebih Besar, Lebih Tidak Mirip: Semakin besar nilai d_{ij} , semakin tidak mirip atau semakin jauh jarak antara objek i dan objek j.
- Diagonal Nol: Jarak dari sebuah objek ke dirinya sendiri (d_{ii}) selalu nol.
- Simetris: Jarak dari objek i ke objek j sama dengan jarak dari objek j ke objek i ($d_{ij} = d_{ji}$).
- Non-negatif: Nilai jarak selalu non-negatif ($d_{ij} \geq 0$).
- Ketaksamaan Segitiga (Triangle Inequality): Untuk metrik jarak yang sesungguhnya, berlaku $d_{ik} \leq d_{ij} + d_{jk}$. Ini berarti jarak langsung antara dua objek tidak pernah lebih besar dari jarak melalui objek ketiga. Namun, untuk beberapa jenis data ketidakmiripan (misalnya, yang berasal dari penilaian subjektif), properti ini mungkin tidak selalu terpenuhi, dan MDS non-metrik dapat menangani situasi ini.

Matriks Jarak (Ketidakmiripan / Dissimilarity Matrix)

- Cara Memperoleh Matriks Kesamaan:
- Data Primer: Responden diminta secara langsung untuk menilai seberapa berbeda dua objek (misalnya, pada skala 1-7, di mana 7 berarti sangat berbeda).
- Data Sekunder (dihitung dari atribut): Jika memiliki data multivariat (misalnya, N objek dengan p variabel/atribut), dapat dihitung jarak antar objek. Beberapa metrik jarak yang umum digunakan adalah: Jarak Euklidian, Jarak Manhattan, Jarak Minkowski, Jarak Hamming, dan lainnya sesuai dengan jenis datanya).

Matriks Jarak (Ketidakmiripan / Dissimilarity Matrix)

- Interpretasi matrix

	A	B	C
A	0	2.828	4.123
B	2.828	0	3.606
C	4.123	3.606	0

- d_{AC} (4.123) adalah nilai terbesar, yang berarti **objek A dan C adalah yang paling tidak mirip** atau paling "jauh" satu sama lain berdasarkan atribut yang diukur. Sebaliknya, d_{AB} (2.828) adalah nilai terkecil, yang berarti **objek A dan B adalah yang paling mirip** atau paling "dekat". Jarak d_{BC} (3.606) berada di antaranya.
 - Diagonal Nol: Jarak dari sebuah objek ke dirinya sendiri (d_{ii}) selalu nol.
 - Simetris: Jarak dari objek i ke objek j sama dengan jarak dari objek j ke objek i ($d_{ij} = d_{ji}$).
 - Non-negatif: Nilai jarak selalu non-negatif ($d_{ij} \geq 0$).
 - Ketaksamaan Segitiga (Triangle Inequality): berlaku $d_{ik} \leq d_{ij} + d_{jk}$
- Apakah $d_{AC} \leq d_{AB} + d_{BC}$?
 $4.123 \leq 2.828 + 3.606$
 $4.123 \leq 6.434$ (Benar ✓)
 - Apakah $d_{AB} \leq d_{AC} + d_{CB}$?
 $2.828 \leq 4.123 + 3.606$
 $2.828 \leq 7.729$ (Benar ✓)
 - Apakah $d_{BC} \leq d_{BA} + d_{CA}$?
 $3.606 \leq 2.828 + 4.123$
 $3.606 \leq 6.951$ (Benar ✓)

Matriks Jarak (Ketidakmiripan / Dissimilarity Matrix)

- Implikasi Ketaksamaan Segitiga (Triangle Inequality)

Misalkan hasil penilaian “Data Primer” adalah sebagai berikut:

- d_{AB} **(Ketidakmiripan antara Merek A dan Merek B) = 2**
 - Alasan responden: "Merek A dan B sama-sama mobil keluarga, harganya mirip, dan dari negara produsen yang sama. Jadi, cukup mirip."
- d_{BC} **(Ketidakmiripan antara Merek B dan Merek C) = 3**
 - Alasan responden: "Merek B itu mobil keluarga, sementara Merek C itu mobil sport. Agak berbeda, tapi keduanya merek Eropa yang terkenal dengan kualitas."
- d_{AC} **(Ketidakmiripan antara Merek A dan Merek C) = 8**
 - Alasan responden: "Merek A itu mobil keluarga yang sangat standar dan ekonomis, sementara Merek C itu mobil sport mewah yang sangat eksklusif. Bagi saya, mereka sangat berbeda sekali!"

Uji ketaksamaan segitiga untuk $d_{AC} \leq d_{AB} + d_{BC}$:

- $8 \leq 2+3$
- $8 \leq 5$

MDS Non-Metrik Lebih Sesuai daripada MDS Metrik (akan dibahas di slide berikutnya)

Transformasi Matrix Kesamaan dan Jarak

- Dari Kesamaan ke Ketidakmiripan:
 - Jika nilai kesamaan s_{ij} memiliki batas atas yang jelas (misalnya, s_{max}), maka $d_{ij} = s_{max} - s_{ij}$ bisa menjadi salah satu cara transformasi sederhana.
 - Transformasi lain bisa berupa $d_{ij} = s_{ii} + s_{jj} - 2s_{ij}$ (jika kesamaan bersifat seperti kovarians).
 - $d_{ij} = 1 - s_{ij}$ (jika s_{ij} dinormalisasi antara 0 dan 1).
- Dari Ketidakmiripan ke Kesamaan:
 - Transformasi seperti $s_{ij} = \max(d) - d_{ij}$ atau $s_{ij} = 1/(1 + d_{ij})$ (jika $d_{ij} \geq 0$) bisa digunakan, meskipun ini kurang umum karena MDS biasanya lebih langsung bekerja dengan atau mengharapkan input ketidakmiripan.

Jenis MDS

- Metric MDS (MDS Metrik) :
Principal Coordinates Analysis (PCoA)
- Non-metric MDS (NMDS/MDS Non-Metrik)
Iteratif

Metric MDS (MDS Metrik)

Mengasumsikan bahwa data input (ketidakmiripan) bersifat metrik (interval atau rasio). Tujuannya adalah untuk menghasilkan peta di mana jarak antar titik secara langsung proporsional dengan nilai ketidakmiripan input.

Algoritma Metric MDS (MDS Metrik)

- Input Data: Data masukan utama untuk MDS adalah matriks ketidakmiripan (dissimilarity matrix) atau matriks kemiripan (similarity matrix) antar pasangan objek. Matriks ini berukuran $N \times N$, di mana N adalah jumlah objek yang dianalisis. Setiap elemen (i,j) dalam matriks ini menunjukkan tingkat ketidakmiripan (atau kemiripan) antara objek i dan objek j .
 - Jika memiliki data multivariat (misalnya, N objek dengan p variabel), langkah pertama adalah menghitung matriks ketidakmiripan ini. Jarak Euklidian adalah salah satu ukuran yang umum digunakan.
- Penentuan Dimensi: Peneliti menentukan jumlah dimensi (k) untuk representasi spasial. Biasanya, dipilih 2 atau 3 dimensi agar mudah divisualisasikan. Tujuannya adalah menemukan representasi berdimensi rendah yang tetap mempertahankan struktur hubungan antar objek sebaik mungkin.

Algoritma Metric MDS (MDS Metrik)

- Algoritma Penskalaan: Algoritma MDS kemudian mencoba untuk menempatkan N objek tersebut dalam ruang k -dimensi. Proses ini bersifat iteratif, di mana posisi titik-titik disesuaikan untuk meminimalkan perbedaan antara jarak pada peta k -dimensi ($\widehat{d}_{ij}$) dengan nilai ketidakmiripan pada data input asli (d_{ij}).
- Evaluasi Kecocokan (Goodness-of-Fit): Kualitas hasil MDS dievaluasi menggunakan ukuran kecocokan, yang paling umum adalah Stress. Nilai stress yang rendah (biasanya di bawah 0.2 atau 0.15, tergantung pada konteks dan jenis MDS) menunjukkan bahwa konfigurasi spasial yang dihasilkan cukup baik dalam merepresentasikan data proksimitas asli. Ukuran lain seperti R^2 juga bisa digunakan, di mana nilai yang mendekati 1 menunjukkan kecocokan yang lebih baik.
- Interpretasi Peta: Peta perseptual yang dihasilkan kemudian diinterpretasikan. Analisis akan melihat pengelompokan objek, posisi relatif antar objek, dan mencoba memahami dimensi-dimensi yang mendasari konfigurasi tersebut. Penting untuk diingat bahwa orientasi (atas-bawah, kiri-kanan) pada peta MDS bersifat arbitrer; yang penting adalah jarak relatif antar titik.

Metric MDS (MDS Metrik)-PCoA

jarak Euklidian dari konfigurasi A=(1,1), B=(4,1), C=(1,5)

Matriks Jarak Asli (D):

	A	B	C
A	0	3	4
B	3	0	5
C	4	5	0

1. Kuadratkan Matriks Jarak ($D^{(2)}$)

Setiap elemen d_{ij} dikuadratkan.

$$D^{(2)} = \begin{pmatrix} 0^2 & 3^2 & 4^2 \\ 3^2 & 0^2 & 5^2 \\ 4^2 & 5^2 & 0^2 \end{pmatrix} = \begin{pmatrix} 0 & 9 & 16 \\ 9 & 0 & 25 \\ 16 & 25 & 0 \end{pmatrix}$$

2. Hitung Matriks Skalar Produk (S)

Matriks S (sering juga disebut B dalam beberapa literatur) dihitung menggunakan formula

double centering pada matriks $-\frac{1}{2}D^{(2)}$. Elemen S_{ij} dihitung sebagai:

$$S_{ij} = -\frac{1}{2}(d_{ij}^2 - \bar{d}_{i.}^{(2)} - \bar{d}_{.j}^{(2)} + \bar{d}_{..}^{(2)})$$

- $S_{11} = -\frac{1}{2}(0 - \frac{25}{3} - \frac{25}{3} + \frac{100}{9}) = -\frac{1}{2}(-\frac{150}{9} + \frac{100}{9}) = -\frac{1}{2}(-\frac{50}{9}) = \frac{25}{9}$
- $S_{12} = -\frac{1}{2}(9 - \frac{25}{3} - \frac{34}{3} + \frac{100}{9}) = -\frac{1}{2}(\frac{81}{9} - \frac{75}{9} - \frac{102}{9} + \frac{100}{9}) = -\frac{1}{2}(\frac{81-75-102+100}{9}) = -\frac{1}{2}(\frac{4}{9}) = -\frac{2}{9}$
- $S_{13} = -\frac{1}{2}(16 - \frac{25}{3} - \frac{41}{3} + \frac{100}{9}) = -\frac{1}{2}(\frac{144}{9} - \frac{75}{9} - \frac{123}{9} + \frac{100}{9}) = -\frac{1}{2}(\frac{144-75-123+100}{9}) = -\frac{1}{2}(\frac{46}{9}) = -\frac{23}{9}$
- $S_{22} = -\frac{1}{2}(0 - \frac{34}{3} - \frac{34}{3} + \frac{100}{9}) = -\frac{1}{2}(-\frac{204}{9} + \frac{100}{9}) = -\frac{1}{2}(-\frac{104}{9}) = \frac{52}{9}$
- $S_{23} = -\frac{1}{2}(25 - \frac{34}{3} - \frac{41}{3} + \frac{100}{9}) = -\frac{1}{2}(\frac{225}{9} - \frac{102}{9} - \frac{123}{9} + \frac{100}{9}) = -\frac{1}{2}(\frac{225-102-123+100}{9}) = -\frac{1}{2}(\frac{100}{9}) = -\frac{50}{9}$
- $S_{33} = -\frac{1}{2}(0 - \frac{41}{3} - \frac{41}{3} + \frac{100}{9}) = -\frac{1}{2}(-\frac{246}{9} + \frac{100}{9}) = -\frac{1}{2}(-\frac{146}{9}) = \frac{73}{9}$

Karena S simetris, $S_{21} = S_{12}$, $S_{31} = S_{13}$, $S_{32} = S_{23}$.

Jadi, matriks Skalar Produk S adalah:

$$S = \begin{pmatrix} 25/9 & -2/9 & -23/9 \\ -2/9 & 52/9 & -50/9 \\ -23/9 & -50/9 & 73/9 \end{pmatrix} \approx \begin{pmatrix} 2.778 & -0.222 & -2.556 \\ -0.222 & 5.778 & -5.556 \\ -2.556 & -5.556 & 8.111 \end{pmatrix}$$

Metric MDS (MDS Metrik)-PCoA

3. Lakukan Dekomposisi Eigen (Eigendecomposition) pada Matriks S

Kita perlu mencari eigenvalues (λ) dan eigenvectors (V) dari matriks S sehingga $SV = V\Lambda$, di mana Λ adalah matriks diagonal dari eigenvalues.

Perhitungan dekomposisi eigen untuk matriks 3×3 secara manual cukup panjang. Untuk tujuan contoh ini, saya akan menggunakan hasil perhitungan (misalnya, menggunakan Python):

Hasil Eigenvalues (λ):

- $\lambda_1 \approx 12.964$
- $\lambda_2 \approx 3.704$
- $\lambda_3 \approx 0$ (atau nilai yang sangat kecil mendekati nol karena presisi numerik)

Hasil Eigenvectors (V , sebagai kolom yang bersesuaian dengan eigenvalues di atas):

- $V_1 \approx \begin{pmatrix} -0.183 \\ -0.598 \\ 0.781 \end{pmatrix}$
- $V_2 \approx \begin{pmatrix} 0.796 \\ -0.556 \\ -0.240 \end{pmatrix}$
- $V_3 \approx \begin{pmatrix} -0.577 \\ -0.577 \\ -0.577 \end{pmatrix}$ (Ini adalah vektor yang terkait dengan eigenvalue nol)

4. Pilih Jumlah Dimensi (k)

(karena ada 2 eigenvalue positif yang signifikan). Kita pilih $k = 2$.

5. Hitung Koordinat Baru (X_{new})

Koordinat baru untuk objek A, B, C dalam k dimensi dihitung sebagai:

$$X_{new} = V_k \Lambda_k^{1/2}$$

$$V_2 = \begin{pmatrix} -0.183 & 0.796 \\ -0.598 & -0.556 \\ 0.781 & -0.240 \end{pmatrix}$$

$$\Lambda_2^{1/2} = \begin{pmatrix} \sqrt{12.964} & 0 \\ 0 & \sqrt{3.704} \end{pmatrix} = \begin{pmatrix} 3.601 & 0 \\ 0 & 1.925 \end{pmatrix}$$

$$X_{new} = \begin{pmatrix} -0.183 & 0.796 \\ -0.598 & -0.556 \\ 0.781 & -0.240 \end{pmatrix} \begin{pmatrix} 3.601 & 0 \\ 0 & 1.925 \end{pmatrix}$$

$$X_{new} = \begin{pmatrix} -0.659 & 1.532 \\ -2.153 & -1.071 \\ 2.812 & -0.462 \end{pmatrix}$$

Jadi, koordinat baru untuk objek-objek dalam 2 dimensi adalah (kira-kira):

- A': (-0.659, 1.532)
- B': (-2.153, -1.071)
- C': (2.812, -0.462)

Metric MDS (MDS Metrik)-PCoA

- Eigenvalues dari PCoA:
 - $\lambda_1 \approx 12.964$
 - $\lambda_2 \approx 3.704$
 - $\lambda_3 \approx 0$ (Kita akan sertakan semua eigenvalue positif untuk penyebut)
- Jumlah dimensi yang kita pilih untuk solusi PCoA (k): $k = 2$

Rumus:

Proporsi Varians Dijelaskan oleh k dimensi = $\frac{\text{Jumlah } k \text{ eigenvalue terbesar}}{\text{Jumlah semua eigenvalue positif}}$

- Jumlah k eigenvalue terbesar (untuk $k = 2$):

$$\lambda_1 + \lambda_2 = 12.964 + 3.704 = 16.668$$

- Jumlah semua eigenvalue positif:

$$\lambda_1 + \lambda_2 + \lambda_3 = 12.964 + 3.704 + 0 = 16.668$$

(Jika λ_3 adalah nilai positif kecil, tetap akan dijumlahkan di sini).

- Hitung Proporsi Varians Dijelaskan:

$$\text{Proporsi Varians} = \frac{16.668}{16.668} = 1.0 \quad \checkmark$$

Hasil: 1.0 atau 100%. Ini berarti 100% varians berhasil dijelaskan oleh solusi 2 dimensi

- Jarak asli antar pasangan objek (d_{ij}):

- $d_{AB} = 3$

- $d_{AC} = 4$

- $d_{BC} = 5$

- Jarak antar pasangan objek dari koordinat PCoA 2D ($\hat{d}_{ij}$):

- $\hat{d}_{A'B'} \approx 3.001$

- $\hat{d}_{A'C'} \approx 4.003$

- $\hat{d}_{B'C'} \approx 5.002$ (Perhitungan $\hat{d}_{ij}$ ini sendiri adalah perhitungan jarak Euklidian manual dari koordinat PCoA).

Rumus Stress-1:

$$\text{Stress-1} = \sqrt{\frac{\sum_{i < j} (d_{ij} - \hat{d}_{ij})^2}{\sum_{i < j} d_{ij}^2}}$$

- Pasangan AB: $(d_{AB} - \hat{d}_{A'B'})^2 = (3 - 3.001)^2 = (-0.001)^2 = 0.000001$

- Pasangan AC: $(d_{AC} - \hat{d}_{A'C'})^2 = (4 - 4.003)^2 = (-0.003)^2 = 0.000009$

- Pasangan BC: $(d_{BC} - \hat{d}_{B'C'})^2 = (5 - 5.002)^2 = (-0.002)^2 = 0.000004$
 $0.000001 + 0.000009 + 0.000004 = 0.000014$

- Pasangan AB: $d_{AB}^2 = 3^2 = 9$

$$\text{Rasio} = \frac{0.000014}{50} = 0.00000028$$


- Pasangan AC: $d_{AC}^2 = 4^2 = 16$

$$\text{Stress-1} = \sqrt{0.00000028} \approx 0.000529 \quad \checkmark$$

- Pasangan BC: $d_{BC}^2 = 5^2 = 25$

$$9 + 16 + 25 = 50$$

Contoh Interpretasi MDS dengan Biplot



- Sebaran Object (Titik Biru).
- PCo1 (Sumbu Horizontal) dan PCo2 (Sumbu Vertikal) : Banyaknya dimensi yang diambil (dari eigenvalue)
- Arah Panah: Menunjukkan arah di mana nilai variabel tersebut meningkat dalam peta PCoA.
- Panjang Panah: Mengindikasikan seberapa kuat pengaruh variabel tersebut dalam menjelaskan sebaran sampel pada dua dimensi ini, atau seberapa baik variabel tersebut direpresentasikan oleh peta 2D ini. Panah yang lebih panjang biasanya lebih berpengaruh.
- Korelasi Positif (panah searah, sudut kecil)
- Korelasi Negatif (panah berlawanan arah, sudut sekitar 180°)
- Kurang Berkorelasi (sudut sekitar 90°)

Pemilihan Dimensi

Jumlah maksimum dimensi yang bisa dihasilkan oleh PCoA adalah **yang lebih kecil** antara:

1. $N-1$ (jumlah objek dikurangi satu)

2. p' (jumlah dimensi independen dalam data asli, yang paling banyak adalah p , jumlah variabel asli).

Contoh:

- **Kasus 1:** Misal memiliki **$N=5$ objek** dan data jaraknya dihitung dari **$p=10$ variabel** asli.
 - $N-1=4$.
 - $p=10$.
 - Maksimum dimensi PCoA yang bisa didapat adalah $\min(4,10)=4$ dimensi.
- **Kasus 2:** Misal memiliki **$N=100$ objek** dan data jaraknya dihitung dari **$p=3$ variabel** asli.
 - $N-1=99$.
 - $p=3$.
 - Maksimum dimensi PCoA yang bisa didapat adalah $\min(99,3)=3$ dimensi. Tidak akan mendapatkan 99 dimensi yang berarti jika data aslinya hanya memiliki informasi untuk 3 dimensi.

Non-metric MDS (NMDS/MDS Non-Metrik)

Mengasumsikan bahwa data input bersifat ordinal (hanya urutan peringkat ketidakmiripan yang penting, bukan nilai absolutnya). Tujuannya adalah untuk menghasilkan peta di mana urutan jarak antar titik sesuai dengan urutan ketidakmiripan input. NMDS lebih fleksibel dan seringkali lebih robust ketika asumsi metrik tidak terpenuhi.

Algoritma Non-Metric MDS (NMDS Metrik)

1. Memulai dengan konfigurasi acak (atau yang diperkirakan) titik-titik dalam dimensi yang diinginkan (misalnya, 2D atau 3D).
2. Menghitung jarak antar titik ($\widehat{d}_{ij}$) dalam konfigurasi ini.
3. Membandingkan urutan dari $\widehat{d}_{ij}$ ini dengan urutan dari d_{ij} asli.
4. Menghitung nilai "Stress", yang merupakan ukuran ketidakcocokan antara dua urutan jarak tersebut.
5. Menggeser posisi titik-titik sedikit demi sedikit untuk mencoba mengurangi nilai Stress.
6. Mengulangi langkah 2-5 sampai nilai Stress tidak bisa dikurangi lagi secara signifikan (konvergen) atau jumlah iterasi maksimum tercapai.

Non-Metric MDS (NMDS)-Iteratif

3 objek (A, B, C) dengan matriks ketidakmiripan (d_{ij}) berikut:

	A	B	C
A	0	2	5
B	2	0	4
C	5	4	0

1. $d_{AB} = 2$ (Paling mirip)
2. $d_{BC} = 4$ (Cukup mirip)
3. $d_{AC} = 5$ (Paling tidak mirip)

Target: Kita ingin menempatkan A, B, C pada sebuah garis (1 Dimensi) sehingga urutan jarak pada garis ($\hat{d}_{ij}$) mengikuti: $\hat{d}_{AB} < \hat{d}_{BC} < \hat{d}_{AC}$.

Langkah 1: Konfigurasi Awal (Tebakan Kasar)

Misalkan kita tempatkan A, B, C secara acak (atau dengan tebakan awal yang kurang baik) pada sebuah garis (sumbu x):

- $x_A = 0$
- $x_B = 6$
- $x_C = 2$

Langkah 2: Hitung Jarak di Peta 1D ($\hat{d}_{ij}$)

- $\hat{d}_{AC} = |x_C - x_A| = |2 - 0| = 2$
- $\hat{d}_{BC} = |x_C - x_B| = |2 - 6| = |-4| = 4$
- $\hat{d}_{AB} = |x_B - x_A| = |6 - 0| = 6$

Langkah 3: Bandingkan Urutan Jarak

- Urutan jarak di peta 1D saat ini: $\hat{d}_{AC}(2) < \hat{d}_{BC}(4) < \hat{d}_{AB}(6)$.
- Urutan target (dari data asli): $d_{AB}(2) < d_{BC}(4) < d_{AC}(5)$.

Ketidakcocokan: Urutan di peta ($\hat{d}_{AC} < \hat{d}_{BC} < \hat{d}_{AB}$) sangat berbeda (bahkan terbalik) dari urutan target ($d_{AB} < d_{BC} < d_{AC}$). Ini berarti "Stress" (ketidakcocokan) tinggi.

Langkah 4: Geser Posisi Titik-Titik (Iterasi)

Karena urutannya tidak cocok, algoritma akan mencoba menggeser posisi A, B, dan C untuk memperbaiki urutan dan mengurangi Stress.

- Kita ingin d_{AB} menjadi yang terkecil. Saat ini A(0) dan B(6) sangat jauh. Kita perlu dekatkan A dan B.
- Kita ingin d_{AC} menjadi yang terbesar. Saat ini A(0) dan C(2) adalah yang terdekat. Kita perlu jauhkan A dan C.
- d_{BC} harus di tengah.

Non-Metric MDS (NMDS)-Iteratif

Konfigurasi Baru (Setelah Iterasi 1):

- $x_A = 0$
- $x_B = 1$ (B digeser mendekati A)
- $x_C = 5$ (C digeser menjauhi A, dan posisinya diatur relatif terhadap B)

Langkah 2 (Ulang): Hitung Jarak di Peta 1D ($\hat{d}_{ij}$) dengan posisi baru

- $\hat{d}_{AB} = |x_B - x_A| = |1 - 0| = 1$
- $\hat{d}_{BC} = |x_C - x_B| = |5 - 1| = 4$
- $\hat{d}_{AC} = |x_C - x_A| = |5 - 0| = 5$

Langkah 3 (Ulang): Bandingkan Urutan Jarak

- Urutan jarak di peta 1D saat ini: $\hat{d}_{AB}(1) < \hat{d}_{BC}(4) < \hat{d}_{AC}(5)$.
- Urutan target (dari data asli): $d_{AB}(2) < d_{BC}(4) < d_{AC}(5)$.

Kecocokan: Urutan di peta sekarang sama persis dengan urutan target! Ini berarti "Stress" akan sangat rendah (idealnya nol jika hanya urutan yang dipertimbangkan dalam contoh sederhana ini).

Langkah 5 (Ulang): Stop atau Lanjut Iterasi

Karena kita sudah mendapatkan urutan yang sempurna dalam contoh sederhana ini, algoritma mungkin akan berhenti atau melakukan beberapa penyesuaian kecil lagi jika menggunakan formula Stress yang sebenarnya (yang juga mempertimbangkan seberapa "pas" nilai jarak $\hat{d}_{ij}$ terhadap transformasi monotonik dari d_{ij}).